Dictamen Ejecutivo

Clasificación de Neumonía — EfficientNetB0 vs. MobileNetV2

MediScan Guatemala · Equipo de Inteligencia Artificial

27 de marzo de 2026

TABLA COMPARATIVA DE MODELOS

Modelo	Accuracy	F1 (Neumonía)	Recall	Tamaño (MB)	Inferencia (ms/img)
EfficientNetB0	0.760	0.852	0.944	15.92	2.26
MobileNetV2	0.945	0.962	0.950	8.98	3.72

Cuadro 1: Métricas evaluadas sobre el conjunto de prueba ($n = 879$ imágenes).

ANÁLISIS SENSIBILIDAD / ACCURACY

Figura 1: Matrices de confusión en el conjunto de prueba: EfficientNetB0 (izquierda) y MobileNetV2 (derecha).

MobileNetV2 supera a EfficientNetB0 en todas las métricas de clasificación. La brecha de accuracy en EfficientNetB0 se explica por sus 175 falsos positivos frente a solo 16 en MobileNetV2.

Un falso positivo genera un estudio adicional innecesario, costo tolerable en comparación. Por ello se prioriza Recall alto aunque se sacrifique Accuracy; sin embargo, EfficientNetB0 no ofrece ventaja real en Recall y acumula un exceso de falsos positivos que saturarían el flujo clínico. MobileNetV2 mantiene alta sensibilidad con mucha mayor especificidad.

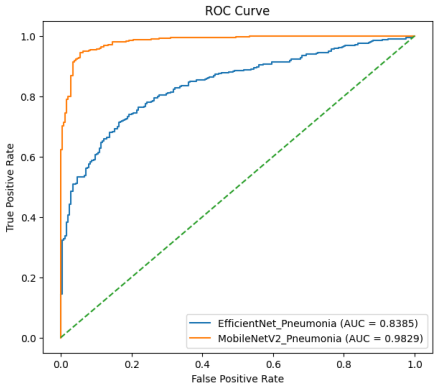

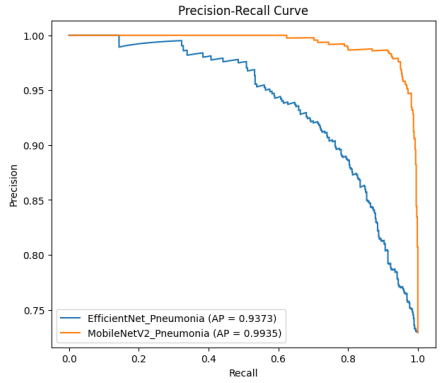

Figura 2: Comparación de curvas ROC (izquierda) y Recall (derecha).

RECOMENDACIÓN AL CTO — PRODUCCIÓN ON-PREMISE SIN GPU

Modelo recomendado: MobileNetV2. Ocupa 44 % menos que EfficientNetB0, entrega el mayor F1 y AUC , y corre en CPU estándar a 3.72 ms/img. EfficientNetB0 es dominado en ambas dimensiones, mayor tamaño *y* menor rendimiento clínico. MobileNetV2 es la opción correcta para el hardware limitado de clínicas rurales guatemaltecas.

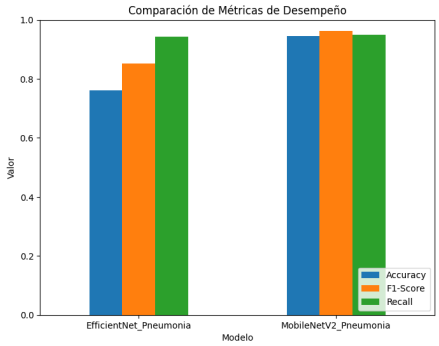

Figura 3: Comparación de Métricas de Desempeño (izquierda)

LIMITACIONES DEL EXPERIMENTO

- El dataset proviene de un único centro.
- El umbral de clasificación se fijó en 0.5 sin optimización clínica.
- El dataset no distingue neumonía bacteriana de viral, lo que limita la utilidad diagnóstica específica.

COSTO EN MB POR PUNTO PORCENTUAL DE F1

$$\text{EfficientNetB0:} \quad \frac{15{,}92}{85{,}2} \approx 0{,}187 \text{ MB/pp} \qquad \text{MobileNetV2:} \quad \frac{8{,}98}{96{,}2} \approx 0{,}093 \text{ MB/pp}$$

MobileNetV2 cuesta la mitad en almacenamiento por cada punto de F1 ganado. El modelo más pesado entrega *menos* rendimiento clínico. No hay trade-off, MobileNetV2 domina.

TIEMPO DE INFERENCIA EN FLUJO CLÍNICO REAL

A 3.72 ms/imagen, MobileNetV2 puede procesar aproximadamente $\lfloor 3{,}600{,}000/3{,}72 \rfloor \approx$ **967** radiografías por hora en CPU. Un radiólogo revisa entre 50 y 100 estudios por jornada de 8 horas; el sistema tiene capacidad $\sim 80\times$ superior. Ambos modelos son viables como herramienta de *pre-triaje*: clasifican y priorizan casos antes de la revisión médica, sin pretender reemplazar al clínico. El tiempo de inferencia no es el cuello de botella en este contexto.

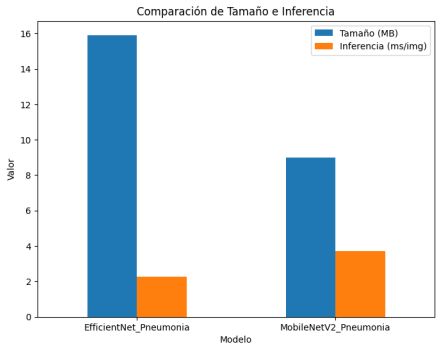

Figura 4: Tamaño del Modelo vs Tiempo de Inferencia (derecha).

CONGELAMIENTO DE CAPAS E IMPACTO EN RESULTADOS

Ambos modelos se entrenaron con las capas base completamente congeladas. MobileNetV2 alcanzó AUC = 0.983 bajo esta configuración, lo que confirma que las representaciones de ImageNet son transferibles al dominio de radiografíasde tórax sin ajuste adicional. EfficientNetB0, arquitecturalmente más profundo, muestra AUC = 0.839, sugiriendo que sus capas superiores requerirían fine-tuning progresivo y descongelar gradualmente con menor LRpara adaptarse al dominio médico. El congelamiento funciona como regularización implícita al reducir el riesgo de destruir pesos preentrenados, pero limita la adaptación al dominio. Para EfficientNetB0, esta restricción fue el factor limitante de su rendimiento.

GENERALIZACIÓN ENTRE EQUIPOS, POBLACIONES Y HOSPITALES

El modelo no puede asumir generalización fuera de su distribución de entrenamiento. Distintos equipos de rayos X producen imágenes con diferente contraste, ruido y artefactos. La población guatemalteca difiere de la población de entrenamiento en densidad ósea, comorbilidades y prevalencia real de neumonía. Para MediScan Guatemala esto implica un riesgo concreto de degradación del rendimiento al desplegar en clínicas rurales con equipos no representados en el dataset. Se recomienda un proceso de validación prospectiva con datos locales previo al despliegue, y evaluar técnicas de *domain adaptation* o re-entrenamiento incremental con radiografías recolectadas en los propios centros.